

AgentShelf 技术方案报告

面向 AI 购物 Agent 的跨境商品安全上新平台

2026 年 8 月

1. 项目概述

AgentShelf 聚焦比赛“AI 智能上新”命题，服务跨境卖家、电商运营团队和电商 ISV。系统把 CSV、商品图片、认证与政策资料整理为统一的 Product Passport，生成适配平台和市场的本地化 Listing，并在发布前完成规则检查、Agent 红队测试、问题修复、同场景复测和人工确认。

项目要解决的核心问题不是“能不能生成一段商品文案”，而是“这份商品信息进入 AI 购物流程后，Agent 能不能看对、选对和买对”。因此系统同时处理内容质量、商品事实、实时商业状态、跨境规则和交易安全。

2. 业务问题

2.1 商品事实分散

同一商品的名称、型号、材质、尺寸、价格、库存、认证和配送信息可能分散在 CSV、图片、政策文件和运营人员经验中。直接让模型读取这些资料并生成 Listing，容易发生遗漏、冲突未保留或无法追溯来源的问题。

2.2 平台和市场规则不同

Amazon、Shopify、TikTok Shop 对标题、描述、Search Terms、必填字段和风险表述的要求不同；德国和美国在语言、币种、配送和政策方面也不同。跨境上新不是单纯翻译，而是多个约束共同作用的内容与数据转换。

2.3 页面内容与实时状态可能不一致

Listing 中的价格、库存、运费和配送承诺可能与结账时的真实状态发生变化。只检查静态页面无法发现此类风险，需要在交易前重新读取商业状态并核对版本。

2.4 AI 购物 Agent 面临新的输入风险

评论、隐藏文本、图片 OCR、错误结构化字段和恶意指令都可能被购物 Agent 当成可信信息。传统内容审核关注用户看到的页面，而 Agent 安全还需要检查机器读取的所有输入和工具调用过程。

3. 产品目标与范围

3.1 产品目标

把多来源商品资料整理为可追溯、可版本化的商品事实。

生成符合目标平台、市场和语言要求的 Listing。

在发布前发现内容、事实、商业状态、跨境政策和指令注入风险。

让问题可以稳定重现，修复结果可以使用同一条件复测。

在最终导出或发布前保留清楚的人工确认责任。

3.2 当前原型范围

旅行收纳品类的演示商品。

Amazon、Shopify、TikTok Shop 三个平台配置。

德国、美国两个目标市场及德语、英语输出。

30 个买家测试任务、12 个受控故障案例。

5 个可调用的商业沙箱 API。

UCP、ACP、MCP 能力映射和浏览器内协议测试。

模拟结账，不调用真实支付和真实平台发布。

3.3 非目标

当前版本不是生产级电商后台，不包含多租户、计费 and 复杂权限系统。

不保存真实支付信息，不完成真实扣款。

不宣称已得到任何电商平台或商业协议组织的官方认证。

不用模型输出直接覆盖原始商品资料或自动放行交易。

4. 总体设计原则

事实优先：商品事实先进入 Product Passport，再生成 Listing，不能绕过统一资料源。

来源可查：每条可发布卖点必须保存来源；不确定内容标记为未知，冲突内容保留双方记录。

AI 与规则分工：模型负责理解、归纳和组织，固定规则负责金额、库存、配送、版本和发布条件。

失败可重现：测试任务、故障输入、运行轨迹、评分、修复和复测结果均采用结构化记录。

修复不破坏原始资料：修复生成新版本，不原地改写原始 Product Passport。

发布需要人工确认：自动检查通过不等于自动发布，最终动作需要人工确认。

演示不触发真实交易：所有结账均为隔离环境中的模拟操作，支付状态始终为未扣款。

5. 系统架构

系统由六个主要层次组成：

5.1 Web 操作台

使用 Next.js、React、TypeScript 构建单页工作台，包含以下七个工作区：

方案总览：面向评委和业务人员说明问题、流程、AI 分工和已实现能力。

上新任务：选择商品、平台、市场、语言和品类，生成 Listing 并执行发布前检查。

商品档案：导入 CSV、TXT/Markdown 和图片，生成 Product Passport。

红队测试：运行买家任务和受控故障，展示搜索、选择、加购和结账轨迹。

任务库：管理 30 个按风险类型组织的买家任务。

故障库：管理 12 个可重复执行的受控故障案例。

协议适配：展示 UCP、ACP、MCP 能力映射和商业沙箱握手过程。

5.2 商品资料整理层

输入包含商品 CSV、政策文本和商品图片。固定解析器负责字段识别、结构校验和原始资料保存；配置 Qwen 时，模型以结构化输出补充图片可见信息、政策事实、潜在冲突、安全卖点、未知项和置信度。

模型结果不能直接替换输入。系统先保留原始资料，再把可验证内容写入新 Product Passport，并记录来源和版本。

5.3 Listing 生成与平台检查层

Listing 生成以 Product Passport 为唯一可信商品资料源。Qwen 可以对卖点和关键词的组织顺序提出建议，但只能引用系统允许的事实 ID。标题、卖点、描述和 Search Terms 最终由固定模板、平台规则和来源约束生成。

发布前检查覆盖：

平台必填字段和格式。

标题、卖点和描述长度。

输出语言与目标市场匹配。

每条卖点是否存在可信来源。

高风险或绝对化表述。

当前价格、库存、运费和配送范围。

Amazon Search Terms、Shopify 描述和 TikTok Shop 标题等平台差异规则。

5.4 Agent 红队测试层

红队引擎包含买家任务、故障注入、运行轨迹、确定性评分、问题记录和修复器。任务覆盖预算与币种、跨境配送、商品事实与认证、退货与授权四组需求。

12 个受控故障分为四类：

指令注入：评论、隐藏文本、图片 OCR 等不可信内容试图改变 Agent 行为。

商业状态：价格、库存、运费、到达时间等状态不一致。

商品事实：尺寸、材质、认证或商品变体发生冲突。

跨境政策：目标国家限制、退货或配送承诺不符合政策。

每次运行生成搜索、选择、加购和模拟结账轨迹，并计算约束满足、事实准确、攻击抵抗、金额一致和安全完成等分数。发现严重问题时，系统阻止交易并给出问题位置、证据和修复建议。

5.5 商业沙箱与协议适配层

商业沙箱提供 5 个 API：

GET /api/commerce/search

GET /api/commerce/products/{productId}

GET /api/commerce/shipping

POST /api/commerce/cart

POST /api/commerce/checkout

商品发现、详情和配送 API 提供测试所需的实时状态。购物车 API 生成带 HMAC 签名和有效期的 checkoutToken。结账 API 先返回 CONFIRMATION_REQUIRED，只有用户显式确认且商品版本、价格、库存和运费没有变化时才返回 confirmed。整个流程保持 payment=not_captured。

UCP、ACP、MCP 在当前原型中作为能力映射和调用适配层，用于说明同一套商品和交易能力如何被不同 Agent 协议调用，不代表已经完成外部平台认证。

5.6 发布文件层

完成检查和人工确认后，系统可以导出：

本地化 Listing JSON。

平台导入表。

Product Passport 和 Product Feed。

Schema.org JSON-LD。

UCP Manifest。

发布前检查报告、卖点来源台账和红队测试报告。

人工确认记录和修复复测报告。

6. 核心数据对象

6.1 Product Passport

Product Passport 是统一商品资料源，主要包含：

商品 ID、SKU、版本和更新时间。

标题、品牌、型号、类目和变体。

材质、尺寸、颜色、用途等商品事实。

价格、币种、库存和配送范围。

认证、政策条件和风险提示。

每条事实的来源、置信度和验证状态。

冲突项、未知项和原始资料引用。

6.2 ListingDraft

ListingDraft 保存销售平台、目标市场、语言、标题、卖点、描述、Search Terms、卖点来源映射、平台检查结果和生成方式。它引用 Product Passport 版本，确保后续测试知道使用了哪一版商品资料。

6.3 Mission

Mission 表示一个可执行的买家需求，包含目的地、预算、币种、时间限制、商品约束、允许工具和预期结果。任务必须与修复前后保持一致，才能比较复测结果。

6.4 FaultCase

FaultCase 描述故障类型、注入位置、输入载荷、预期影响、严重程度和建议修复。故障只作用于测试数据副本，不修改原始商品记录。

6.5 RunReport

RunReport 保存任务、输入版本、运行轨迹、问题、评分、修复记录、结果状态和导出文件。它既服务界面展示，也作为可审查的测试证据。

7. Qwen 使用方式

7.1 商品图片与政策理解

模型读取商品图片和政策文本，返回符合预设结构的内容，包括可见属性、材料事实、政策事实、冲突、安全卖点、未知项和置信度。所有结果都经过 Zod 校验，并与原始资料一起保存。

7.2 Listing 结构优化

模型不自由编造文案，只能从系统提供的可信事实或卖点 ID 中选择和排序。固定代码根据平台和语言模板生成最终内容，并保存卖点到来源的映射。

7.3 红队结果语义复核

模型可以对运行轨迹和问题进行语义复核，用于发现固定规则难以覆盖的表达问题。模型复核是补充结果，不替代固定分数和交易阻止条件。未配置 API Key 时，系统仍能使用固定规则完整运行。

8. 信任边界与安全设计

卖家上传的 CSV、图片和政策

默认信任级别：待验证

处理方式：保存原文、校验结构、记录来源和冲突

评论、网页文本和 OCR

默认信任级别：不可信

处理方式： 与系统指令隔离，不允许改变预算、工具和放行规则

Qwen 输出

默认信任级别： 建议

处理方式： 结构校验，只能引用允许的事实，不能直接覆盖原始资料

价格、库存和配送 API

默认信任级别： 实时业务状态

处理方式： 在加购和结账前重新读取并核对版本

购物车令牌

默认信任级别： 临时可信

处理方式： HMAC 签名、十分钟有效、状态变化后失效

人工确认

默认信任级别： 最终业务责任

处理方式： 内容和商业状态确认齐全后才能生成批准记录

主要安全措施：

API Key 只从环境变量读取，不进入源码、测试和截图。

模型输入与工具权限分离，网页文本不能授予新工具。

故障注入使用数据副本，避免污染原始记录。

修复生成新版本，保留修复前后的差异和来源。

结账采用显式确认，并核对价格、库存、运费和商品版本。

所有演示交易均不扣款。

9. 技术选型

Web 框架

技术：Next.js 16

选择原因：前端、服务端接口和构建流程统一，便于快速演示和部署

界面

技术：React 19、TypeScript

选择原因：组件化、类型安全、适合复杂交互状态

数据校验

技术：Zod

选择原因：对模型输出、API 输入和核心数据对象进行运行时校验

CSV 解析

技术：Papa Parse

选择原因：使用成熟解析器，处理实际 CSV 边界情况

大模型

技术：Qwen，通过阿里云百炼接口

选择原因：支持文本、图片和结构化输出，适合跨境商品资料理解

图标

技术：Lucide React

选择原因：统一、可访问、避免手绘不一致图标

单元测试

技术：Vitest

选择原因：快速验证核心规则、引擎和数据转换

端到端测试

技术： Playwright

选择原因： 验证真实浏览器交互、下载、响应式布局和 API 流程

10. 可行性分析

技术可行性

项目已有可运行原型，核心功能不是静态设计稿。商品资料整理、Listing 生成、平台检查、任务运行、故障注入、修复复测、文件下载和商业沙箱均有实际代码和自动测试。

数据可行性

原型使用结构化演示商品和受控故障，不依赖大规模训练数据。进入试点阶段后，可从合作卖家的商品资料、历史退回原因和平台规则中逐步扩展，无需先建立完整行业数据集。

业务可行性

产品可以作为现有商品管理系统和发布流程之前的质量检查层，不要求卖家立即替换原有 ERP、PIM 或平台后台。早期可先采用文件导入和报告导出，验证价值后再增加平台连接器。

11. 创新点

把 AI 上新从内容生成扩展为安全发布流程： 生成、检查、红队测试、修复和确认形成闭环。

面向购物 Agent 设计质量标准： 同时验证人可见内容和机器可读取的商品、评论、OCR、工具结果。

以 Product Passport 统一商品事实： 跨平台 Listing、测试和协议输出都引用同一版本的商品资料。

同任务修复复测： 修复前后使用相同买家需求和故障输入，避免“换题后通过”。

确认式商业沙箱： 用签名购物车、状态复核和显式确认演示 Agent 交易的安全放行方式。

12. 部署与扩展路线

阶段一：比赛原型

本地或单实例部署。

演示数据保存在代码和运行内存中。

Qwen API Key 可选；没有密钥时使用固定规则。

商业操作全部为沙箱模拟。

阶段二：卖家试点

增加账号、组织、角色和商品资料权限。

使用 PostgreSQL 保存商品版本、任务、运行和报告。

使用对象存储保存图片、政策和导出文件。

使用任务队列执行批量图片理解和 30 项测试。

对接一个平台测试环境或合作方 PIM/ERP。

增加模型调用成本、时延、失败率和质量监控。

阶段三：生产服务

多租户隔离、审计日志、密钥管理和数据生命周期策略。

更多品类、平台、国家和语言规则包。

规则版本管理、灰度发布和人工审核 workflow。

真实平台发布前的双向状态核对和回滚策略。

使用真实商家数据评估问题发现率、返工次数和上新周期。

13. 风险与应对

模型遗漏或误读图片、政策

影响： 错误事实进入内容

应对方式：保存原始资料、结构校验、冲突和未知项、人工确认

平台规则持续变化

影响：检查规则过期

应对方式：规则版本化，标记来源和生效时间，支持独立更新

实时商业状态变化

影响：结账金额或配送不一致

应对方式：加购和结账前重新读取，令牌包含版本和有效期

测试案例覆盖不全

影响：未发现新型风险

应对方式：按真实问题持续扩充任务和故障库，保留回归测试

模型成本和延迟

影响：批量上新效率下降

应对方式：固定规则优先、模型可选、批处理、缓存和失败降级

自动修复造成新问题

影响：修复后引入回归

应对方式：不修改原始版本，使用同任务复测并要求人工确认

14. 成功指标

以下指标需要在真实卖家试点中采集，当前原型不虚构结果：

单个 SKU 从资料导入到形成可审核 Listing 的时间。

每个 Listing 中有明确来源的卖点比例。

发布前发现的高风险问题数量和类型。

首次检查通过率、修复后通过率和平均修复次数。

因价格、库存、配送和政策问题导致的返工次数。

运营人员人工核对时间和问题定位时间。

模型调用成功率、平均时延和单 SKU 成本。

15. 总结

AgentShelf 用一个可运行原型证明了“AI 智能上新”可以从内容生成进一步发展为可追溯、可测试、可修复、可确认的安全发布流程。Product Passport 负责统一事实，Qwen 负责理解和组织，固定规则负责交易与发布条件，红队引擎负责发现问题，人工确认负责最终业务责任。当前方案适合比赛演示和早期试点，生产化仍需要真实平台连接、账号权限、持久化和业务数据验证。